

تمرین سری پنجم: درس یادگیری ماشین

(1)

الف) در مورد ماشین بردار پشتیبان خطای کلی به چه معناست؟

(a) میزان فاصله خط از بردارهای پشتیبان

(b) میزان دقت svm برای پیشبینی نتایج داده‌های تست

(c) مقدار آستانه خطا در svm

خطای کلی به معنای مقدار آستانه خطا در SVM است. این مقدار نشان می‌دهد که چه میزان از داده‌ها را می‌توان در طرف اشتباه از مرز جداسازی قرار داد. اگر خطای کلی صفر باشد، یعنی ماشین بردار پشتیبان سخت یا SVM with hard margin است که هیچ خطایی را تحمل نمی‌کند. اگر خطای کلی مثبت باشد، یعنی ماشین بردار پشتیبان نرم است که برخی از خطاها را تحمل می‌کند. بنابراین، پاسخ صحیح به سوال شما گزینه c) مقدار آستانه خطا در SVM است.

ب) وقتی پارامتر c روی بی‌نهایت تنظیم می‌شود کدام یک از موارد زیر صحیح می‌باشد؟

(a) ابر صفحه بهینه در صورت وجود صفحه‌ای خواهد بود که داده‌ها را بطور کامل جدا می‌کند

(b) طبقه بندی کننده soft margin داده‌ها را جدا می‌کند

(c) هیچ یک از موارد فوق

گزینه a) صحیح است؛ با ضریب c به خطا اهمیت می‌دهیم؛ c برابر بی‌نهایت سعی می‌کند خطا نداشته باشد در این حالت، ما یک طبقه بندی کننده hard margin داریم که سعی می‌کند یک ابر صفحه بهینه پیدا کند که داده‌ها را بطور کامل جدا کند.

ج) اثر بخشی یک svm به کدام یک از موارد زیر بستگی دارد؟

(a) انتخاب هسته

(b) پارامترهای هسته

(c) پارامتر soft margin

(d) همه موارد

♦ انتخاب هسته: تابع هسته برای تبدیل داده‌های ورودی از فضای ویژگی اصلی به فضای ویژگی با ابعاد بالاتر استفاده می‌شود. انواع مختلفی از توابع هسته وجود دارد، مانند خطی، چندجمله‌ای، تابع پایه شعاعی (RBF) و سیگموئید. هر تابع هسته ویژگی‌های خاص خود را دارد و برای انواع مختلف داده‌ها مناسب است

♦ پارامترهای هسته: پارامترهای هسته مقادیری هستند که تأثیر تابع هسته را بر روی داده‌ها تعیین می‌کنند. برای مثال، در تابع هسته چندجمله‌ای، پارامترهای هسته شامل درجه و ثابت هستند. این پارامترها باید به گونه‌ای انتخاب شوند که بتوانند داده‌ها را به خوبی تمایز دهند

◆ پارامتر  $\text{soft margin}$ : پارامتر  $\text{soft margin}$  یا  $C$  یک عامل تنظیم است که میزان جریمه را برای داده‌های نادرست طبقه بندی شده تعیین می‌کند. اگر  $C$  بزرگ باشد،  $\text{SVM}$  سعی می‌کند هیچ داده ای را اشتباه طبقه بندی نکند، اما ممکن است به خطر بیفتد. اگر  $C$  کوچک باشد،  $\text{SVM}$  می‌تواند برخی از داده‌ها را اشتباه طبقه بندی کند، اما ممکن است حاشیه بزرگتری داشته باشد

(د) در خصوص روش  $\text{soft margin}$  و  $\text{hard margin}$  با هسته گاوسی کدام یک از موارد زیر صحیح است؟

- (a) با کاهش پارامتر امکان رخداد بیش‌برازش افزایش می‌یابد.
- (b) با افزایش هسته گاوسی نرخ خطا در داده‌های آزمون افزایش نمی‌یابد.
- (c) با کاهش ضریب جریمه، در الگوریتم  $\text{soft margin svm}$  دسته بندی دچار بیش‌برازش می‌شود.
- (d) با افزایش ضریب جریمه، در الگوریتم  $\text{soft margin svm}$  میزان داده‌های آموزش نادرست دسته بندی شده کاهش، اما داده‌های آزمون درست دسته بندی شده افزایش می‌یابد.


گزینه c صحیح است. زیرا با کاهش ضریب جریمه یا پارامتر  $C$ ، کمتر به داده های نادرست طبقه بندی شده جریمه می‌کند و ممکن است حاشیه را بیش از حد بزرگ کند و داده ها را بیش‌برازش کند. گزینه های a و b غلط هستند چون با کاهش پارامتر، احتمال بیش‌برازش کاهش می‌یابد و با افزایش هسته گاوسی، نرخ خطا در داده های آزمون ممکن است افزایش یابد. گزینه d نیز غلط است چون با افزایش ضریب جریمه،  $\text{SVM}$  سخت گیرتر می‌شود و ممکن است داده های آموزش را کمتر اشتباه طبقه بندی کند، اما داده های آزمون را بیشتر اشتباه طبقه بندی کند.

(2)

یک ماشین بردار پشتیبان خطی سخت، ( $\text{SVM Linear Hard}$  یا  $\text{SVM}$  خطی بدون در نظر گرفتن پناهی) در یک مسأله دسته بندی دو کلاسه در فضای دو بعدی با  $N$  داده آموزشی داده شده است. نتیجه حاصل  $K=2$  بردار پشتیبان بوده است. در صورتی که یک داده برچسب دار دلخواه به مجموعه داده‌های قبلی اضافه کرده و مجدداً دسته بند را آموزش دهیم، حداکثر چند بردار پشتیبان ممکن است بدست آید؟

حداکثر تعداد بردارهای پشتیبان برابر با تعداد داده های آموزشی است. زیرا اگر همه داده ها روی یک خط قرار داشته باشند، همه آن‌ها بردار پشتیبان خواهند بود. اما این حالت کم احتمال است و معمولاً تعداد بردارهای پشتیبان کمتر از تعداد داده های آموزشی است. بنابراین، اگر یک داده برچسب دار دلخواه به مجموعه داده های قبلی اضافه کنیم، حداکثر تعداد بردارهای پشتیبان برابر با  $N+1$  خواهد بود. البته این تعداد ممکن است کمتر باشد اگر داده اضافه شده دور از ابر صفحه جداکننده باشد و تأثیری بر حاشیه نداشته باشد.

۳- برای داده های نشان داده شده در شکل زیر، کدام خروجی می‌تواند به ترتیب حاصل ماشین بردار خطی، ماشین بردار با کرنل گاوسی  $\sigma = 1$  و ماشین بردار پشتیبان با کرنل گاوسی  $\sigma = 0.25$  باشد.



عرض هسته ( $\sigma$ ): انعطاف پذیری مرز تصمیم را کنترل می‌کند. مقادیر  $\sigma$  بالاتر منجر به مرزهای هموارتر می‌شود و الگوهای جهانی بیشتری را ثبت می‌کند. مقادیر  $\sigma$  کمتر منجر به مرزهای پیچیده‌تر می‌شود و بر الگوهای محلی تمرکز می‌کند.

درک تأثیر عرض هسته:  $\sigma = 1$ : انعطاف پذیری متوسط، متعادل کردن الگوهای جهانی و محلی.

$\sigma = 0.25$ : مرزهای پیچیده‌تر، با تأکید بر الگوهای محلی.

تجزیه و تحلیل داده‌ها و خروجی‌ها: نقاط داده را بررسی کنید: آیا آن‌ها به صورت خطی در فضای اصلی خود قابل تفکیک هستند؟ آیا آن‌ها الگوهای غیر خطی را نشان می‌دهند که ممکن است از هسته گاوسی بهره‌مند شوند؟ مرزهای تصمیم‌گیری بالقوه را در نظر بگیرید: برای  $\sigma = 1$ ، مرزی را تجسم کنید که الگوهای جهانی و محلی را متعادل می‌کند. برای  $\sigma = 0.25$ ، مرزی را تصور کنید که بر جزئیات محلی تمرکز دارد و به طور بالقوه مناطق تصمیم‌گیری پیچیده‌تری را ایجاد می‌کند. خروجی‌ها را با مرزهای تصمیم‌مورد انتظار مطابقت دهید: به نظر می‌رسد کدام خروجی بیشتر از یک مرز هموارتر و جهانی‌تر ( $\sigma = 1$ ) ناشی می‌شود؟ کدام خروجی با یک مرز پیچیده‌تر و متمرکز به صورت محلی ( $\sigma = 0.25$ ) تراز بهتری دارد؟

ملاحظات اضافی: پارامترهای SVM: سایر پارامترها مانند منظم‌سازی نیز می‌توانند بر مرز تصمیم‌گیری تأثیر بگذارند. پیچیدگی داده‌ها: پیچیدگی ذاتی داده‌ها در خود نقش دارد.

طبق مفاهیم بالا شکل A برای کرنل گاوسی، سیگما برابر با 1 مطابقت دارد و شکل E برای کرنل گاوسی، سیگما برابر با 0.25 مطابقت می‌کند. اندازه سیگما را اگر درست انتخاب نکنیم و اگر خیلی کوچک در نظر بگیریم داده‌ها را حفظ می‌کند و مشکل اورفیت داریم.

۴- فرض کنید که داده‌های جدول ۱ را بخواهیم توسط یک ماشین بردار پشتیبان جدا کنیم.

الف) آیا این کار امکان‌پذیر است؟

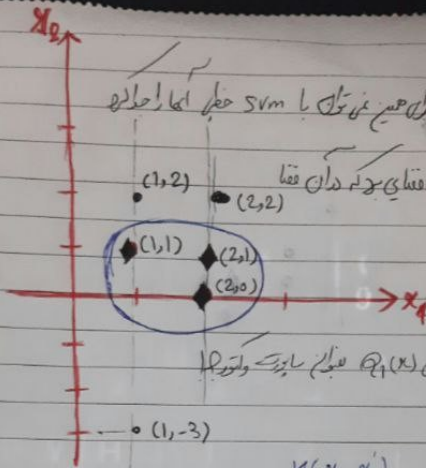
Data Point	Label
(1,1)	1
(2,1)	1
(2,0)	1
(1,2)	-1
(2,2)	-1
(1,-3)	-1

ب) در صورت استفاده از تابع تبدیل غیرخطی  $\varphi_1(x) = (x_1^2 + x_2^2, x_1 - x_2)$  و  $\varphi_2(x) = (x_2, x_1 - x_2)$  چگونه؟

ج) آیا دو نقطه  $A = \begin{bmatrix} 4 \\ 0 \end{bmatrix}$  و  $B = \begin{bmatrix} 9 \\ -4 \end{bmatrix}$  برای تابع  $\varphi_1(x)$  به عنوان ساپورت وکتورها هستند؟

Data Point	Label
------------	-------

(1,1)	1
(2,1)	1
(2,0)	1
(1,2)	-1
(2,2)	-1
(1,-3)	-1



الف) خطی که جدایی بین خطی نیست بر هیچ خطی با SVM خطی اما احاطه  
با استفاده از کرنل می توان داده را به فضای سه بعدی برداریم و آن خطی  
جدایی بین خطی دارند

ب)  $A = \begin{bmatrix} 4 \\ 0 \end{bmatrix}$ ,  $B = \begin{bmatrix} 9 \\ -4 \end{bmatrix}$  برای  $\Phi_1(x)$  مناسب است و آنرا

$$K(x, x')$$

$$\Phi_1(x) = (x_1^2 + x_2^2, x_1 - x_2)$$

$$g(x) = \left( \sum_{i=1}^m \alpha_i y_i^T k(x_i^T, x) \right) + b$$

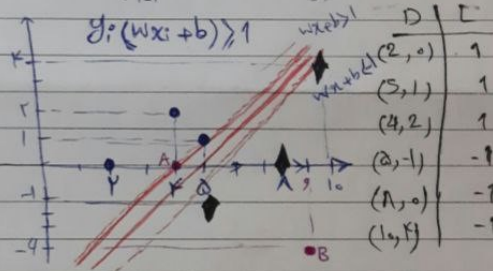
$$\Phi_2(x) = (x_2, x_1 - x_2)$$

$$wx + b = 0$$

$$W = \sum_{i=1}^n \alpha_i y_i x_i$$

$$b = y_i - \sum_{i=1}^m \lambda_i y_i x_i x_j$$

$\Phi_1(x)$



$$L(x, \lambda, y) = f(x, y) - \lambda g(x, y) \quad \text{تابع لاگرانژ}$$

$$\nabla_{x, y, \lambda} L(x, y, \lambda) = 0$$

$$\frac{dL}{dx} = 0, \quad \frac{dL}{dy} = 0, \quad \frac{dL}{d\lambda} = 0$$

$$\frac{d}{dx} (f(x) + \alpha g(x)) \Big|_{x=x_0} = 0$$

$$g(x) = 0$$


ج) نقطه A بسیار نزدیک به ابرضا که گفته قرار دارد و آنرا به یک مرکز تبدیل می کنند

اما نقطه B بسیار دور از ابرضا است و آنرا به یک مرکز خاص می تبدیل می کنند

PAPCO STATIONERY

$$\Phi_2(x) = (x_2, x_1 - x_2)$$

D	L
(1,0)	1
(1,1)	1
(0,2)	1
(2,-1)	-1
(2,0)	-1
(-3,4)	-1

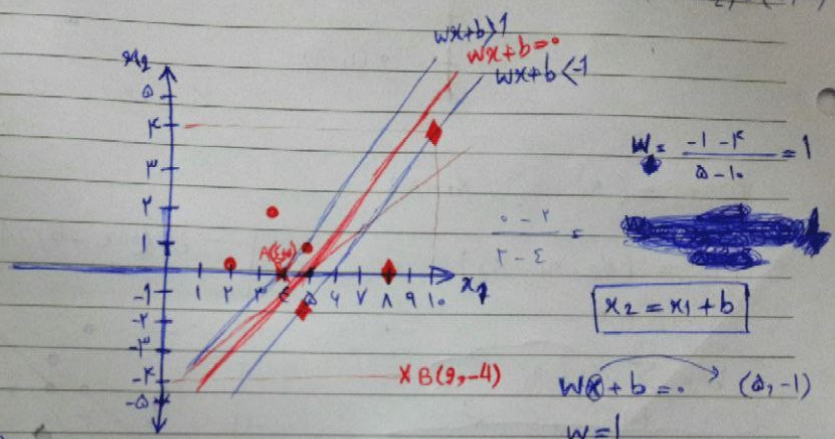


د) حال آنکه که در شکل فضای مرکز شده و فضای  $\Phi_2(x)$   
به صورت خطی قابل تفکیک نیستند



$(-5, 4) \mid -1$

$(x_1, x_2) \in (\partial_1, -1)$



$$x_1 - x_2 = (x_1^2 + x_2^2) + b$$

$$(5, -1) \rightarrow 5 - (-1) = (5^2 + (-1)^2) + b \Rightarrow$$

$$wx + b = 0 \rightarrow (5, -1)$$

$$w = 1$$

$$x_1 - x_2 + \delta = -1$$

$$\sqrt{-1 - \delta + \delta} = -1$$